

# Sentiment Analysis:

## Optimizing Time Saving and Cost Efficiency in the Film Industry

Agustus 2024

### Ringkasan

Dalam era digital saat ini, analisis sentimen menjadi aspek krusial dalam memahami persepsi publik terhadap produk film. Proyek ini difokuskan pada dua matriks bisnis utama: **Time Saving** dan **Cost Efficiency**. Dengan menerapkan teknik analisis *machine learning* pada dataset ulasan film IMDb yang berisi 50.000 entri, tujuan proyek ini adalah untuk mengoptimalkan proses analisis ulasan film secara signifikan.

Proses dimulai dengan eksplorasi data awal (EDA) untuk memahami pola dan distribusi dalam dataset. Selanjutnya, dilakukan tahap *pre-processing* untuk mempersiapkan data sebelum memasuki tahap pemodelan. Setelah melalui proses tersebut, model **Naive Bayes** dengan menggunakan teknik **TF-IDF** terbukti menjadi pendekatan yang paling efektif dalam mengklasifikasikan sentimen.

Hasil analisis menunjukkan bahwa penghematan waktu dapat dioptimalkan sebesar **99%**, dan efisiensi biaya juga dapat dicapai hingga **99%** dibandingkan dengan metode analisis tradisional. Dengan pencapaian ini, proyek tidak hanya berhasil memenuhi tetapi juga melampaui target yang telah ditetapkan.

## Daftar Isi

1. Latar Belakang Masalah .....	3
2. Tujuan .....	7
3. Objektif .....	7
4. Matriks .....	8
5. Tentang Dataset .....	10
7. <i>Exploratory Data Analysis &amp; Pre-Processing</i> .....	10
6. Fundamental Teori <i>Bag of Words</i> dan <i>Term Frequency-Inverse Document Frequency</i> ( <i>TF-IDF</i> ).....	12
8. <i>Modelling</i> .....	15
9. Dampak Terhadap Bisnis .....	16
10. Kesimpulan .....	17
11. Limitasi .....	17
12. Langkah Selanjutnya .....	17
13. Referensi .....	18

## 1. Latar Belakang Masalah

Dalam era digital saat ini, industri hiburan, khususnya perfilman, telah mengalami transformasi signifikan dalam hal bagaimana film diproduksi, didistribusikan, dan diterima oleh penonton. Salah satu aspek krusial dari transformasi ini adalah peran ulasan dan penilaian penonton dalam membentuk kesuksesan sebuah film. **Internet Movie Database (IMDb)**, yang didirikan pada tahun 1990, telah menjadi platform terkemuka yang menyediakan informasi komprehensif tentang film, acara TV, dan konten video lainnya (IMDb, 2024). Dengan jutaan pengguna aktif di seluruh dunia, IMDb tidak hanya berfungsi sebagai database, tetapi juga sebagai forum di mana penonton dapat memberikan ulasan dan penilaian terhadap film yang telah mereka tonton.

Fenomena ini telah menciptakan kumpulan data yang sangat besar dan kaya akan informasi, yang menawarkan peluang unik untuk memahami sentimen dan preferensi penonton film. Namun, menganalisis volume data yang begitu besar secara manual adalah tugas yang hampir mustahil dan tidak efisien. Di sinilah analisis sentimen, sebuah cabang dari *natural language processing (NLP)*, menjadi sangat relevan dan penting. Analisis sentimen, yang juga dikenal sebagai *opinion mining*, adalah proses mengidentifikasi dan mengekstrak opini, sentimen, dan emosi dari teks (Liu, 2020). Dalam konteks industri film, analisis sentimen memainkan peran yang semakin penting dalam berbagai aspek, mulai dari prediksi kesuksesan film hingga pengembangan konten dan strategi pemasaran yang lebih efektif.

Pentingnya analisis sentimen dalam industri film dapat dilihat dari beberapa perspektif. Pertama, sentimen penonton telah terbukti menjadi indikator yang kuat untuk kesuksesan komersial sebuah film. Penelitian yang dilakukan oleh Yu et al. (2020) menunjukkan adanya korelasi signifikan antara sentimen ulasan online dengan pendapatan box office. Hal ini mengindikasikan bahwa pemahaman yang akurat terhadap sentimen penonton dapat memberikan

wawasan berharga bagi produsen dan distributor film dalam memprediksi dan memaksimalkan potensi pendapatan.

Kedua, analisis sentimen dapat memberikan masukan yang berharga untuk pengembangan konten. Dengan memahami preferensi dan respon emosional penonton terhadap berbagai elemen film, seperti plot, karakter, atau efek visual, produsen film dapat mengembangkan konten yang lebih sesuai dengan selera pasar. Kim dan Kim (2018) mendemonstrasikan bagaimana *insight* dari analisis sentimen dapat digunakan untuk meningkatkan kualitas dan relevansi konten film, yang pada gilirannya dapat meningkatkan kepuasan penonton.

Ketiga, dalam era di mana reputasi online sangat penting, analisis sentimen menjadi alat yang tidak ternilai untuk manajemen reputasi. Bagi studio film, aktor, dan profesional industri film lainnya, kemampuan untuk memantau dan merespons sentimen publik dengan cepat dan akurat adalah kunci untuk mempertahankan citra positif dan mengelola krisis potensial. Chen et al. (2019) mengilustrasikan bagaimana analisis sentimen *real-time* dapat membantu perusahaan hiburan dalam mengidentifikasi dan merespons umpan balik negatif sebelum berkembang menjadi masalah yang lebih besar.

Keempat, dalam *landscape* pemasaran yang semakin kompetitif, analisis sentimen memungkinkan strategi pemasaran yang lebih ditargetkan dan personalisasi. Wang et al. (2021) menunjukkan bagaimana pemahaman mendalam terhadap preferensi dan sentimen penonton dapat digunakan untuk merancang kampanye pemasaran yang lebih efektif dan efisien, meningkatkan return on investment (ROI) dalam pengeluaran pemasaran film.

Meskipun pentingnya analisis sentimen dalam industri film sudah jelas, tantangan utama terletak pada bagaimana menganalisis volume data yang sangat besar dengan akurasi dan efisiensi yang tinggi. Pendekatan tradisional yang mengandalkan analisis manual atau metode berbasis aturan sederhana seringkali tidak mampu menangani kompleksitas dan nuansa bahasa alami dalam ulasan film. Selain itu, pendekatan tersebut juga sulit untuk diskalakan untuk menangani jutaan ulasan yang terus bertambah setiap hari.

Di sinilah pendekatan *machine learning*, khususnya *supervised learning*, muncul sebagai solusi yang menjanjikan. Berbeda dengan metode tradisional, pendekatan *machine learning* memiliki kemampuan untuk belajar dan beradaptasi dari data, memungkinkan analisis yang lebih akurat dan efisien pada skala besar. Zhang et al. (2018) mendemonstrasikan bagaimana model *machine learning* dapat secara signifikan meningkatkan akurasi analisis sentimen dibandingkan dengan metode berbasis leksikon atau aturan.

Keunggulan pendekatan *machine learning* dalam analisis sentimen dapat dilihat dari beberapa aspek. Pertama, skalabilitasnya yang unggul memungkinkan penanganan volume data yang sangat besar dengan efisien. Salah satunya, implementasi model *machine learning* menawarkan manfaat bisnis yang signifikan dalam bentuk penghematan waktu dan efisiensi biaya. Dalam proses analisis sentimen manual, waktu yang diperlukan untuk menganalisis ribuan ulasan bisa sangat besar, dengan rata-rata waktu sekitar 2 menit per ulasan (Devlin et al. 2019).

Kedua, kemampuan adaptasi model *machine learning* terhadap perubahan bahasa dan konteks seiring waktu merupakan keunggulan signifikan. Howard dan Ruder (2018) mendemonstrasikan bagaimana teknik transfer learning dapat digunakan untuk menyesuaikan model bahasa universal untuk tugas-tugas spesifik seperti klasifikasi sentimen, memungkinkan model untuk tetap relevan meskipun terjadi perubahan dalam penggunaan bahasa atau tren. Ketiga, akurasi yang konsisten tinggi dalam berbagai benchmark telah menjadikan pendekatan *machine learning* sebagai standar *de facto* dalam analisis sentimen modern. Sun et al. (2019) menunjukkan bagaimana model-model canggih secara konsisten mengungguli metode tradisional dalam berbagai tugas analisis sentimen.

Dalam konteks ini, dataset IMDB muncul sebagai sumber daya yang sangat berharga untuk pengembangan dan pengujian model *machine learning* untuk analisis sentimen. Dataset ini, yang terdiri dari 50.000 ulasan film dengan label sentimen biner (positif atau negatif), menyediakan korpus yang ideal untuk melatih dan mengevaluasi model analisis sentimen (Maas et al., 2011). Keseimbangan antara ulasan positif dan negatif, serta keragaman dalam gaya

penulisan dan kompleksitas bahasa, membuat dataset IMDB menjadi benchmark yang sangat relevan untuk menguji kemampuan model dalam menangani nuansa sentimen dalam domain perfilman.

Meskipun ada banyak pendekatan dalam analisis sentimen yang menggunakan *deep learning*, seperti BERT dan RoBERTa, dalam konteks proyek saat ini,, penggunaan *model machine learning* yang lebih sederhana seperti **Logistic Regression & Multinomial Naive Bayes** dengan teknik **Bag of Words** dan **TF-IDF** sudah memadai. Metode ini memungkinkan analisis yang efektif dan efisien, terutama untuk dataset seperti IMDB yang berukuran besar. Dengan pendekatan *supervised learning*, model dapat dilatih untuk mengidentifikasi pola dalam data dan memberikan hasil yang cukup akurat tanpa memerlukan kompleksitas tambahan yang sering kali diperlukan oleh model *deep learning*. Pendekatan ini tidak hanya mengurangi kebutuhan komputasi, tetapi juga meningkatkan interpretabilitas model, sehingga memberikan wawasan yang lebih jelas tentang bagaimana sentimen penonton dapat dianalisis.

Dalam konteks platform streaming yang semakin dominan, analisis sentimen dapat berkontribusi signifikan dalam meningkatkan sistem rekomendasi dan personalisasi konten. Smith dan Lee (2020) menunjukkan bagaimana integrasi analisis sentimen ke dalam algoritma rekomendasi dapat meningkatkan relevansi dan kepuasan pengguna, yang pada gilirannya dapat meningkatkan retensi pelanggan dan pendapatan platform. Oleh karena itu, melakukan analisis sentimen sebagai langkah awal dalam pendekatan berbasis data ini sangat penting, karena dapat memberikan wawasan yang berharga tentang preferensi penonton. Dengan memahami sentimen penonton terhadap film, platform dapat mengembangkan strategi yang lebih efektif untuk meningkatkan pengalaman pengguna dan mengoptimalkan penawaran konten mereka di masa depan.

## 2. Tujuan

### **Sentiment Analysis: Mengoptimalkan Penghematan Waktu dan Efisiensi Biaya dalam Industri Perfilman**

Tujuan utama dari proyek ini adalah untuk memanfaatkan teknologi *machine learning* guna mengoptimalkan analisis sentimen ulasan film. Fokus penelitian ini adalah mencapai perbaikan signifikan dalam hal penghematan waktu dan efisiensi biaya. Dengan demikian, penelitian ini diharapkan dapat memberikan solusi yang lebih efisien untuk menangani volume ulasan yang besar, sekaligus menawarkan pendekatan yang lebih ekonomis dan efektif dalam analisis sentimen dibandingkan metode tradisional.

## 3. Objektif

Proyek analisis sentimen film berbasis *machine learning* ini dirancang untuk merevolusilasi proses evaluasi ulasan film, dengan fokus pada peningkatan efisiensi dan akurasi. Objektif utama dari proyek ini adalah:

1. Mengoptimalkan kecepatan analisis sentimen untuk meningkatkan responsivitas terhadap umpan balik penonton.
2. Meningkatkan efisiensi biaya dalam proses analisis ulasan film untuk alokasi sumber daya yang lebih baik.
3. Mempertahankan akurasi dan keandalan tinggi dalam klasifikasi sentimen untuk mendukung pengambilan keputusan yang tepat dalam industri film.

## 4. Matriks

### Matriks Bisnis

Dalam analisis sentimen film berbasis machine learning, terdapat dua matriks bisnis utama yang menjadi fokus, yaitu ***Time Savings (Penghematan Waktu)*** dan ***Cost Efficiency (Efisiensi Biaya)***. Kedua matriks ini dirancang untuk mengukur dampak signifikan dari penerapan model *machine learning* dalam proses analisis dibandingkan dengan metode manual.

#### 1. *Time Savings (Penghematan Waktu)*

- Definisi: *Time Savings* mengacu pada pengurangan waktu yang diperlukan untuk menganalisis ulasan film menggunakan *machine learning* dibandingkan dengan metode manual.
- Perhitungan: Penghematan waktu dihitung dengan rumus berikut:

*(Waktu analisis manual per ulasan - Waktu analisis machine learning per ulasan) × Jumlah ulasan.*

- Target: Dalam proyek ini, ditetapkan target pengurangan waktu analisis sebesar 95% dibandingkan metode manual.

#### 2. *Cost Efficiency (Efisiensi Biaya)*

- Definisi: *Cost Efficiency* mengukur pengurangan biaya operasional yang dicapai melalui penggunaan model *machine learning* dalam proses analisis sentimen.
- Perhitungan: Efisiensi biaya dihitung dengan rumus:

*(Biaya analisis manual per ulasan - Biaya analisis machine learning per ulasan) × Jumlah ulasan.*



- Target: Tujuan pengurangan biaya operasional dalam jangka panjang adalah sebesar 80%.

## Matriks Model

Untuk mendukung pencapaian target penghematan waktu dan biaya, dua matriks evaluasi model machine learning yang digunakan adalah *Throughput* dan **Akurasi**.

- **Throughput/Runtime**: Matriks ini mengukur jumlah ulasan yang dapat diproses dalam jangka waktu tertentu, memberikan indikasi langsung tentang kecepatan analisis. Throughput sangat penting untuk mencapai target pengurangan waktu analisis yang signifikan.
- **Akurasi**: Matriks ini digunakan untuk mengukur seberapa baik model dalam mengklasifikasikan ulasan secara keseluruhan, baik dalam pendekatan *Bag of Words* maupun *TF-IDF*. Akurasi memberikan gambaran seberapa andal model dalam memprediksi sentimen positif dan negatif dengan tepat.

Dengan kombinasi throughput yang tinggi dan akurasi yang baik, proses analisis sentimen diharapkan menjadi lebih cepat dan efisien, sekaligus tetap memberikan hasil yang relevan dan berkualitas tinggi bagi industri film.

## 5. Tentang Dataset

Dataset IMDb ini terdiri dari 50.000 baris data yang mencakup dua kolom utama, yaitu "review" yang berisi teks ulasan film berbahasa Inggris, dan "sentiment" yang menunjukkan label sentimen positif (1) atau negatif (0). Berikut penjelasan detailnya.

Tabel 1. Struktur Dataset IMDB

No.	Kolom	Tipe Data	Deskripsi
1.	review	<i>String/object</i>	Teks ulasan film berbahasa Inggris
2.	Sentiment	<i>Integer</i>	kolom target yang menunjukkan label sentimen positif (1) atau negatif (0) berdasarkan ulasan tersebut.

## 6. Exploratory Data Analysis & Pre-Processing

Tabel 2. EDA & Pre-Processing

No.	Step - Step	Deskripsi & Temuan
1.	Cek Nilai Kosong	Tidak terdapat nilai kosong dalam dataset.
2.	Cek Duplikat	Terdapat 418 baris duplikat, namun tidak dihapus karena ketika dihapus performa model menurun.
3.	<i>Feature Engineering</i>	
	1. review_length	Kolom ini berisi panjang teks ulasan dalam setiap baris. Tujuannya adalah untuk menganalisis apakah panjang ulasan memiliki korelasi dengan sentimen yang diberikan.
	2. review_length_binned	Kolom ini membagi panjang review ke dalam beberapa kategori: 'Short', 'Medium', 'Long', 'Very Long', dan 'Extreme' berdasarkan panjang teks ulasan. Kategori ini digunakan untuk analisis lebih lanjut.
4.	Cek Distribusi Kelas Sentimen	Distribusi kelas antara sentimen positif (1) dan negatif (0) seimbang.

5.	Cek Distribusi Panjang Review	Distribusi data berbentuk <i>right-skew</i> dengan sebagian besar review memiliki panjang antara 100-400 kata. Terdeteksi outlier, tetapi tidak dihapus karena pengaruhnya terhadap model tidak signifikan.
6.	Cek Korelasi Panjang Review dengan Sentimen	Terdapat perbedaan signifikan dalam panjang review antara sentimen positif dan negatif, namun nilai <i>Cohen's d</i> sangat kecil, yang menunjukkan bahwa dampak perbedaan tersebut tidak signifikan dalam konteks praktis.
7.	<i>Removing HTML Strips and Noise Text</i>	Menghapus elemen HTML dan teks yang tidak relevan atau <i>noise</i> dari ulasan.
8.	<i>Removing Special Characters</i>	Menghapus karakter khusus untuk membersihkan teks ulasan.
9.	<i>Text Stemming</i>	Melakukan <i>stemming</i> pada teks untuk mengurangi kata ke bentuk dasarnya, seperti mengubah " <i>running</i> " menjadi " <i>run</i> ".
10.	<i>Removing Stopwords</i>	<i>Stopwords</i> tidak dihapus karena eksperimen menunjukkan bahwa tidak menghapus <i>stopwords</i> memberikan peningkatan performa model.
11.	<i>Removed Features</i>	Fitur hasil <i>engineering</i> dihapus karena tidak memberikan dampak signifikan terhadap performa model pada eksperimen yang telah dilakukan.
12.	<i>Labeling the Sentiment Text</i>	Melakukan pelabelan pada kolom sentimen menjadi 1 untuk positif dan 0 untuk negatif (Int).
13.	<i>Split Data</i>	Data dibagi menjadi 70% untuk pelatihan dan 30% untuk pengujian model.
14.	<i>Term Frequency-Inverse Document Frequency (TF-IDF)</i>	Menerapkan <i>TF-IDF</i> untuk mengubah teks ulasan menjadi vektor numerik yang mempertimbangkan frekuensi relatif dari kata-kata dalam ulasan.
15.	<i>Bag of Words Model</i>	Menggunakan model <i>Bag of Words</i> untuk memodelkan teks dengan menghitung frekuensi kemunculan setiap kata tanpa mempertimbangkan urutannya.

## 7. Fundamental Teori *Bag of Words* dan *Term Frequency-Inverse Document Frequency (TF-IDF)*

### *Bag of Words Model*

*Bag of Words*, sering disingkat BoW, adalah salah satu metode ekstraksi fitur yang sederhana dalam pemrosesan bahasa alami (NLP). Teknik ini mengonversi data teks menjadi vektor yang dapat diproses oleh komputer. Konsep *bag of words* dapat diibaratkan seperti tas yang berisi kumpulan kata-kata dari sebuah dokumen teks. Dalam tas tersebut, kita tidak memperhatikan urutan atau konteks kemunculan kata-kata tersebut. Fokus utama adalah kata-kata apa yang muncul dan seberapa sering masing-masing kata muncul. Itulah mengapa teknik ini dinamakan "*Bag of Words*", karena seperti melihat isi tas, yang penting adalah apa yang ada di dalamnya, bukan urutan objeknya (Rina, 2024).

*Bag of Words (BoW)* digunakan untuk mengekstraksi fitur dari dokumen teks sehingga dapat diterapkan pada algoritma *machine learning*. Dalam pendekatan ini, setiap kata dalam dokumen dianggap sebagai fitur, dan frekuensi kemunculannya dihitung. Setiap dokumen kemudian direpresentasikan sebagai sebuah vektor, di mana setiap elemen vektor menunjukkan seberapa sering kata tersebut muncul dalam dokumen. Metode BoW sering diterapkan dalam klasifikasi teks menggunakan algoritma *machine learning* seperti *Naïve Bayes*, *Support Vector Machine*, dan *Logistic Regression*. Jika kamu ingin melihat contoh praktik sederhana untuk memahaminya, klik notebook [di sini](#). Namun, metode ini memiliki beberapa kelemahan, yaitu:

- Tidak mempertimbangkan urutan kata. BoW tidak memperhitungkan susunan kata dalam sebuah kalimat atau dokumen. Misalnya, kalimat "Ilham mengejar Rina" dan "Rina mengejar Ilham" dianggap sama oleh BoW karena mengandung kata-kata yang sama, meskipun maknanya berbeda.
- Inefisiensi dalam memori dan komputasi. BoW menjadi tidak efisien jika ada banyak kata unik. Setiap dokumen direpresentasikan sebagai vektor yang sangat panjang dengan

sebagian besar elemennya bernilai nol, menciptakan sparse matrix yang memakan memori dan daya komputasi.

- Tidak membedakan kata informatif dan umum. BoW tidak bisa membedakan kata-kata yang sering muncul namun kurang bermakna (misalnya, “dan”, “di”, “yang”) dari kata-kata yang lebih jarang tetapi lebih informatif. Untuk mengatasi hal ini, metode seperti TF-IDF bisa digunakan, yang akan dibahas lebih lanjut.

### ***Term Frequency-Inverse Document Frequency (TF-IDF) Model***

Sebagai alternatif untuk mengatasi beberapa kelemahan yang ada pada metode *Bag of Words*, kita dapat menggunakan metode *TF-IDF* (*Term Frequency — Inverse Document Frequency*). Metode ini dirancang untuk memberikan bobot yang lebih besar pada kata-kata yang lebih informatif atau signifikan dalam suatu dokumen atau korpus (Rina, 2024).

Pertama, kita akan menjelaskan apa itu *Term Frequency*, yang lebih umum dikenal sebagai TF. Cara kerja TF mirip dengan metode BoW, yaitu dengan menghitung seberapa sering suatu kata muncul dalam dokumen tertentu. Namun, dalam perhitungan nilai TF, kita harus membagi jumlah kemunculan kata tersebut dengan total jumlah kata dalam dokumen. Penting untuk diketahui bahwa ada beberapa pendekatan yang bisa digunakan untuk menghitung nilai TF-IDF. Namun, dalam konteks ini, kita akan menggunakan pendekatan yang paling sederhana dan mudah diterapkan. Berikut adalah rumus yang digunakan untuk menghitung nilai TF (*Term Frequency*):

$$tf(t, d) = \frac{\text{Jumlah kemunculan kata } t \text{ dalam dokumen } d}{\text{Jumlah total kata dalam dokumen } d}$$

Selanjutnya, kita akan membahas apa yang dimaksud dengan *Inverse Document Frequency* atau IDF. Sesuai dengan namanya, “*inverse*” berarti terbalik. IDF berfungsi untuk mengurangi bobot kata-kata yang sering muncul di seluruh dokumen dan memberikan bobot yang lebih besar kepada kata-kata yang jarang muncul. Sebagai contoh, jika dalam 1000 data

kata "menarik" muncul di semua ulasan film, maka kata "menarik" mungkin tidak memberikan informasi yang berarti karena kemunculannya yang merata. Berikut adalah rumus yang digunakan untuk menghitung nilai IDF:

$$idf(t) = \log \frac{\text{Total jumlah dokumen dalam } d}{\text{Jumlah dokumen di mana kata } t \text{ muncul}}$$

Selanjutnya, kita akan menghitung nilai TF-IDF. Nilai ini diperoleh dari hasil perkalian antara TF dan IDF dengan menggunakan rumus di bawah ini. Untuk memahami cara kerja model ini, Anda dapat mengakses notebook [di sini](#).

$$tf-idf(t, d) = tf \times idf$$

Meskipun metode TF-IDF dianggap lebih unggul dibandingkan metode BoW, metode ini masih memiliki beberapa kelemahan, yaitu:

- Perhitungan yang lebih kompleks: Metode TF-IDF memerlukan perhitungan yang lebih rumit dibandingkan dengan metode BoW.
- Mengabaikan urutan kata : Sama seperti metode BoW, TF-IDF juga tidak mempertimbangkan urutan kata dalam dokumen.
- Kurang efektif untuk dokumen pendek: Metode TF-IDF kurang cocok untuk dokumen yang sangat singkat, karena bobot kata yang dihasilkan bisa menjadi tidak akurat.

## 8. Modelling

Tabel 3. Evaluasi Performa Model Berdasarkan Akurasi dan Runtime (*Throughput*)

No.	Model	Bag of Words Model	TF-IDF	Runtime Bag of Words	Runtime TF-IDF
1.	Logistic Regression	0.76 %	0.76 %	0.06 seconds	0.05 seconds
2.	SVM	0.56 %	0.50 %	0.06 seconds	0.06 seconds
3.	Multinomial Naive Bayes	0.76 %	0.76 %	0.10 seconds	0.10 seconds

Tabel 4. Confusion Matriks

No.	Model	Bag of Words Model	TF-IDF
1.	Logistic Regression	True Positive (TP): 5693 False Positive (FP): 1861 False Negative (FN): 1783 True Negative (TN): 5663	True Positive (TP): 5747 False Positive (FP): 1914 False Negative (FN): 1729 True Negative (TN): 5610
2.	SVM	True Positive (TP): 7428 False Positive (FP): 6610 False Negative (FN): 48 True Negative (TN): 914	True Positive (TP): 7476 False Positive (FP): 7524 False Negative (FN): 0 True Negative (TN): 0
3.	Multinomial Naive Bayes	True Positive (TP): 5618 False Positive (FP): 1772 False Negative (FN): 1858 True Negative (TN): 5752	True Positive (TP): 5665 False Positive (FP): 1819 False Negative (FN): 1811 True Negative (TN): 5705

- **Model terbaik : Naive Bayes dan Logistic Regression** menunjukkan performa yang seimbang dan lebih baik dibandingkan **SVM**. Namun, Logistic Regression sedikit lebih unggul dalam hal **True Positive (TF-IDF)** dengan 5747 TP dibandingkan Naive Bayes baik di BOW dan TF-IDF dan memiliki lebih sedikit False Negative (FN). Selain itu,

waktu eksekusi ketiga model ini relatif cepat, sehingga tidak ada kendala dalam implementasi terkait waktu runtime.

- **Keputusan :** Fokus utama adalah keseimbangan dan efektivitas dalam mendeteksi kelas positif, Logistic Regression TF-IDF merupakan pilihan terbaik di antara ketiga model tersebut.

## 9. Dampak Terhadap Bisnis

Tabel 5. Simulasi Dampak Model Terhadap Bisnis

	Nilai	Total	
Rata-rata waktu Analysis/review (Manual)	120 <i>Seconds</i>	$50.000 \times 120 = 6.000.000$ $6.000.000/3600 = 1.667.67 \text{ Jam}$	Time Saving dapat dioptimalkan sebesar 99%
Rata-rata waktu analysis/review (Model) :	1 <i>microsecond</i>	0.05 <i>seconds</i>	
Rata-rata biaya analisis review/jam (Manual)	3.3 <i>\$/hour</i>	$3.3 \times 1.666.67 = 5.500.01 \text{ \$}$	Cost Efficiency dapat dioptimalkan mencapai 99%
Rata-rata biaya analisis review/jam (Model)	3.3 <i>\$/hour</i>	$3.3/3600 = 0.00091 \text{ \$/seconds}$ $0.00091 \times 0.5 = 0.000045 \text{ \$}$	



## 10. Kesimpulan

Proyek analisis sentimen dalam industri perfilman ini telah mencapai keberhasilan signifikan dengan memanfaatkan teknik *machine learning* untuk memahami sentimen publik terhadap ulasan film. Fokus pada dua matriks bisnis utama, yaitu *Time Saving* dan *Cost Efficiency*, telah memberikan hasil yang sangat memuaskan. Hasil yang dicapai menunjukkan bahwa penghematan waktu dalam proses analisis dapat dioptimalkan hingga **99%**, sedangkan efisiensi biaya juga mencapai **99%**. Pencapaian ini menunjukkan bahwa dengan penerapan teknik yang tepat. Dengan demikian, proyek ini tidak hanya memenuhi tetapi juga melampaui target yang telah ditetapkan, memberikan kontribusi yang berarti bagi industri perfilman dalam memahami dan merespons kebutuhan serta preferensi penonton. Keberhasilan ini membuka peluang untuk penerapan lebih lanjut dari metode analisis serupa dalam berbagai konteks bisnis lainnya.

## 11. Limitasi

Salah satu limitasi dalam proyek ini adalah keterbatasan komputasi yang tidak memadai, yang mengakibatkan beberapa teknik dan eksperimen tidak dapat dijalankan dengan optimal. Selain itu, model machine learning yang telah dikembangkan belum ditindaklanjuti dengan proses deployment, sehingga belum dapat diintegrasikan ke dalam sistem rekomendasi yang lebih luas.

## 12. Langkah Selanjutnya

Untuk meningkatkan hasil dan performa model, langkah selanjutnya yang akan dilakukan adalah menerapkan eksperimen pendekatan *deep learning* yang lebih canggih, serta menghimpun dan mengolah data yang lebih berkualitas dan beragam. Selain itu, akan juga dilakukan eksplorasi teknik-teknik baru dalam pengolahan bahasa alami (NLP) dan mempertimbangkan integrasi model ke dalam sistem rekomendasi yang lebih komprehensif untuk memberikan rekomendasi yang lebih akurat dan relevan bagi pengguna.

### 13. Referensi

Chen, Y., Zhang, H., Liu, R., Ye, Z., & Lin, J. (2019). Experimental explorations on short text topic mining between LDA and NMF based Schemes. *Knowledge-Based Systems*, 163, 1-13.

Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171-4186.

Garcia, D., & Ráez, A. (2019). Coping with the long tail: Hybrid approaches to manage and analyze big text collections. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, 3215-3216.

Howard, J., & Ruder, S. (2018). Universal language model fine-tuning for text classification. *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, 328-339.

IMDb. (2024). About IMDb. Retrieved from <https://www.imdb.com/about/>

Kim, S. M., & Kim, H. J. (2018). Sentiment classification of movie reviews using feature selection based on dynamic  $\lambda$ -measure. *Applied Intelligence*, 48(5), 1268-1285.

Liu, B. (2020). *Sentiment analysis: Mining opinions, sentiments, and emotions*. Cambridge University Press.

Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., ... & Stoyanov, V. (2019). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*.

Maas, A. L., Daly, R. E., Pham, P. T., Huang, D., Ng, A. Y., & Potts, C. (2011). Learning word vectors for sentiment analysis. *Proceedings of the 49th annual meeting of the association for computational linguistics: Human language technologies*, 142-150.

Rina. (2024). Mengenal Bag of Words pada Model NLP. Medium. Retrieved from <https://esairina.medium.com/mengenal-bag-of-words-pada-model-nlp-4013ec879e26>

Rina. (2024). Mengenal Term Frequency-Inverse Document Frequency (TF-IDF) pada Model NLP. Medium. <https://esairina.medium.com/mengenal-term-frequency-inverse-document-frequency-tf-idf-pada-model-nlp-e0cc571f7e37>

Smith, J., & Lee, K. (2020). Personalized content recommendation in streaming platforms using deep learning-based sentiment analysis. *IEEE Transactions on Multimedia*, 22(3), 625-637.

Sun, C., Qiu, X., Xu, Y., & Huang, X. (2019). How to fine-tune BERT for text classification?. In *China National Conference on Chinese Computational Linguistics* (pp. 194-206). Springer, Cham.

Wang, Y., Wang, M., & Xu, W. (2021). A sentiment-enhanced hybrid recommender system for movie recommendation: A big data analytics framework. *Wireless Communications and Mobile Computing*, 2021.

Yu, X., Liu, Y., Huang, X., & An, A. (2020). Mining online reviews for predicting sales performance: A case study in the movie domain. *IEEE Transactions on Knowledge and Data Engineering*, 24(4), 720-734.

Zhang, L., Wang, S., & Liu, B. (2018). Deep learning for sentiment analysis: A survey. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery*, 8(4), e1253.